

# Jardel\_Metodos\_Numericos\_Unidade\_2\_Semana\_2

November 2, 2020

\*\*

Disciplina:\*\* Métodos Numéricos

\*\*

Semestre:\*\* 2020.2

\*\*

Aluno:\*\* Jardel Brandon de Araujo Regis

\*\*

Mátricula:\*\* 201621250014

\*\*

2ª Unidade:\*\* Álgebra Linear Computacional

```
[1]: import numpy as np
import scipy.linalg as sla
```

## 0.0.1 Eliminação Gaussiana

```
[2]: def elimin_gaussiana(a,b,imp = False, norma='inf'):
    import numpy as np #colocadas aqui para evitar problemas de namespace
    import scipy.linalg as sla #colocadas aqui para evitar problemas de
    ↪namespace

    #matriz estendida Me
    b = np.mat(b).T
    Me = np.concatenate((a,b), axis=1)

    if imp: print('Matriz estendida: \n',Me,'\n\n')
    if imp: print('='*80)
    for j in range(Me.shape[-1] - 2): #coluna
        if imp: print('Operação na coluna', j)
        if imp: print('='*80, '\n\n')
        for i in range(j+1, Me.shape[0]): #linha
            Me[i] = Me[i] - (Me[i,j]/Me[j,j])*Me[j] #operações com cada linha
            if imp: print('Operação na linha', i, ':',Me[i], '\n')
```

```

        if imp: print('Matriz escalonando: \n',Me,'\n')
        if imp: print('='*80)
    if imp: print('\nMatriz escalonada: \n',Me,'\n')

    Matriz_A = np.delete(Me, -1, axis=1) #matriz de coeficientes escalonada
    Vetor_b = Me[:,-1] #matriz de termos independentes escalonada
    Vetor_x = sla.solve_triangular(Matriz_A, Vetor_b) # solução do sistema
↪escalonado

    if imp: print('='*80,'\n\nSolução do sistema: \n', Vetor_x)

    #verificação do erro do sistema
    if norma is 'inf': norma = np.inf
    if norma is '-inf': norma = -np.inf
    Erro = sla.norm(b - a.dot(Vetor_x),ord = norma)

    return (Matriz_A, Vetor_b, Vetor_x, Erro)

```

```

[3]: def elimin_gaussiana_pivoteamento_parcial(a, b, imp=False, norma='inf'):
    # matriz estendida Me
    b = np.mat(b).T
    Me = np.concatenate((a, b), axis=1)
    linhas, colunas = Me.shape
    Me_copia = np.copy(Me.astype('float'))
    a_copia = np.copy(a.astype('float'))
    b_copia = np.copy(b.astype('float'))

    if imp: print('Matriz estendida: \n', Me_copia, '\n\n')
    if imp: print('=' * 80)
    for j in range(colunas - 2): # coluna
        maior_coluna_indice = np.argmax(np.abs(Me_copia[j:, j])) + j
        if maior_coluna_indice >= j:
            Me_copia[[j, maior_coluna_indice]] = Me_copia[[maior_coluna_indice,
↪j]]
            a_copia[[j, maior_coluna_indice]] = a_copia[[maior_coluna_indice,
↪j]]
            b_copia[[j, maior_coluna_indice]] = b_copia[[maior_coluna_indice,
↪j]]

            if imp: print("Trocando linha: ",maior_coluna_indice, "->",
↪Me_copia[maior_coluna_indice], "Pela linha: ", j, "->", Me_copia[j])
            if imp: print('Operação na coluna', j)
            if imp: print('=' * 80, '\n\n')
            for i in range(j + 1, linhas): # linha
                Me_copia[i] = np.subtract(Me_copia[i], (Me_copia[i, j] /
↪Me_copia[j, j]) * Me_copia[j]) # operações com cada linha
            if imp: print('Operação na linha', i, ':', Me_copia[i], '\n')

```

```

        if imp: print('Matriz escalonando: \n', Me_copia, '\n')
        if imp: print('=' * 80)
        if imp: print('\nMatriz escalonada: \n', Me_copia, '\n')

        Matriz_A = np.delete(Me_copia, -1, axis=1) # matriz de coeficientes
↪escalonada
        Vetor_b = Me_copia[:, -1] # matriz de termos independentes escalonada
        Vetor_x = sla.solve_triangular(Matriz_A, Vetor_b) # solução do sistema
↪escalonado

        if imp: print('=' * 80, '\n\nSolução do sistema: \n', Vetor_x)

        # verificação do erro do sistema
        if norma is 'inf': norma = np.inf
        if norma is '-inf': norma = -np.inf
        Erro = sla.norm(b_copia.transpose() - a_copia.dot(Vetor_x), ord=norma)

        return (Matriz_A, Vetor_b, Vetor_x, Erro)

```

```

[4]: a = np.array([[2,3,-1],[4,4,-3],[2,-3,1]])
      b = np.array([5,3,-1])
      M = elimin_gaussiana(a,b)
      M

```

```

[4]: (matrix([[ 2,  3, -1],
               [ 0, -2, -1],
               [ 0,  0,  5]]),
      matrix([[ 5],
               [-7],
               [15]]),
      array([[1.],
              [2.],
              [3.]]),
      0.0)

```

```

[5]: sla.solve(a,b)

```

```

[5]: array([1., 2., 3.])

```

**Exercise 1** Interprete o erro apresentado acima e altere a função `elimin_gaussiana`, para que esse erro não ocorra. Essa abordagem de escolha do pivô como o elemento da coluna onde se realizará as operações que está na diagonal principal da matriz de coeficientes deixa o processo bastante sensível a propagação de erros durante as operações.

```

[6]: a = np.array([[1,1,1],[4,4,2],[2,1,-1]])
      b = np.array([1,2,0])

```

```
[7]: elimin_gaussiana_pivoteamento_parcial(a,b)
```

```
[7]: (array([[ 4. ,  4. ,  2. ],
            [ 0. , -1. , -2. ],
            [ 0. ,  0. ,  0.5]]),
      array([ 2. , -1. ,  0.5]),
      array([ 1., -1.,  1.]),
      0.0)
```

```
[8]: sla.solve(a,b)
```

```
[8]: array([ 1., -1.,  1.])
```

### Example 3

Resolva o sistema:

$$\begin{aligned}x_1 + 4x_2 + 52x_3 &= 57 \\ 27x_1 + 110x_2 - 3x_3 &= 134 \\ 22x_1 + 2x_2 + 14x_3 &= 38\end{aligned}$$

pelo método de eliminação gaussiana. Após escalonamento e aplicando, substituição reatrativa ao sistema escalonado, obtemos

$$x_1 = 4.5 \quad x_2 = 0 \quad x_3 = 1.01$$

bastante diferente de

$$x_1 = 1 \quad x_2 = 1 \quad x_3 = 1$$

a solução exata do sistema.

**Exercise 2** Quantifique o erro da solução encontrada acima. Esse exemplo ilustra bem os efeitos de propagação de erros quando escalonamos matrizes usando o método de eliminação gaussiana convencional. Esse efeito pode ser mensurado melhor quando consideramos o problema com elementos com grande diferença de escala, como a seguir. Existem duas alternativas à essa escolha de pivô por posição:

pivotamento parcial: o pivô escolhido é o maior número na coluna a ser avaliada;

pivotamento total: o pivô escolhido é o maior número na matriz de coeficientes (ver livro do Chapra).

```
[9]: a = np.array([[1, 4, 52], [27, 110, -3], [22, 2, 14]])

erro = sla.norm(a, ord=np.inf)
erro
```

```
[9]: 140.0
```

**Exercise 3** Refaça o exemplo 3 usando eliminação gaussiana com pivotamento parcial e compare os erros do resultado obtido aqui com os do exemplo.

```
[10]: a = np.array([[1,4,52],[27,110,-3],[22,2,14]])
      b = np.array([57,134,38])
```

```
[11]: elimin_gaussiana(a, b)
```

```
[11]: (matrix([[ 1, 4, 52],
               [ 0, 2, -1407],
               [ 0, 0, -61631]]),
      matrix([[ 57],
               [-1405],
               [-61631]]),
      array([[1.],
             [1.],
             [1.]]),
      0.0)
```

```
[12]: elimin_gaussiana_pivoteamento_parcial(a,b)
```

```
[12]: (array([[ 27.         , 110.         , -3.         ],
               [  0.         , -87.62962963, 16.44444444],
               [  0.         ,  0.         , 52.09721048]]),
      array([134.         , -71.18518519, 52.09721048]),
      array([1., 1., 1.]),
      0.0)
```

```
[13]: sla.solve(a,b)
```

```
[13]: array([1., 1., 1.])
```

O resultado obtido está de acordo com o cálculo analítico

**Exercise 4** Implemente uma versão da função `elimin_gaussiana` que faça o pivotamento parcial. Compare os resultados e erros com os exemplos anteriores.

#### Example 4

Resolva o sistema

$$0.02x_1 + 0.01x_2 = 0.02$$

$$x_1 + 2x_2 + x_3 = 1$$

$$x_2 + 2x_3 + x_4 = 4$$

$$100x_3 + 200x_4 = 800$$

```
[14]: a = np.array([[0.02, 0.01, 0, 0], [1, 2, 1, 0], [0, 2, 0, 1], [0, 0, 100, 200]])
      b = np.array([0.02, 1, 4, 800])
```

```
[15]: elimin_gaussiana(a, b)
```

```
[15]: (matrix([[ 2.00000000e-02,  1.00000000e-02,  0.00000000e+00,
                0.00000000e+00],
               [ 0.00000000e+00,  1.50000000e+00,  1.00000000e+00,
                0.00000000e+00],
               [ 0.00000000e+00,  0.00000000e+00, -1.33333333e+00,
                1.00000000e+00],
               [ 0.00000000e+00,  0.00000000e+00,  0.00000000e+00,
                2.75000000e+02]]),
      matrix([[2.0e-02],
              [0.0e+00],
              [4.0e+00],
              [1.1e+03]]),
      array([[ 1.],
             [ 0.],
             [-0.],
             [ 4.]]),
      0.0)
```

```
[16]: elimin_gaussiana_pivoteamento_parcial(a,b)
```

```
[16]: (array([[1.0e+00, 2.0e+00, 1.0e+00, 0.0e+00],
               [0.0e+00, 2.0e+00, 0.0e+00, 1.0e+00],
               [0.0e+00, 0.0e+00, 1.0e+02, 2.0e+02],
               [0.0e+00, 0.0e+00, 0.0e+00, 5.5e-02]]),
      array([1.0e+00, 4.0e+00, 8.0e+02, 2.2e-01]),
      array([1., 0., 0., 4.]),
      0.0)
```

```
[17]: sla.solve(a,b)
```

```
[17]: array([1., 0., 0., 4.])
```

O resultado obtido está de acordo com o cálculo analítico

### Example 5

Resolva o sistema

$$\begin{aligned}x + y + z &= 1 \\ 2x + y - z &= 0 \\ 2x + 2y + z &= 1\end{aligned}$$

```
[18]: a = np.array([[1, 1, 1], [ 2, 1, -1], [2, 2, 1]])
      b = np.array([1, 0, 1])
```

```
[19]: elimin_gaussiana(a, b)
```

```
[19]: (matrix([[ 1,  1,  1],
               [ 0, -1, -3],
               [ 0,  0, -1]]),
       matrix([[ 1],
               [-2],
               [-1]]),
       array([[ 1.],
              [-1.],
              [ 1.]]),
       0.0)
```

```
[20]: elimin_gaussiana_pivoteamento_parcial(a,b)
```

```
[20]: (array([[ 2. ,  1. , -1. ],
               [ 0. ,  1. ,  2. ],
               [ 0. ,  0. ,  0.5]]),
       array([0. , 1. , 0.5]),
       array([ 1., -1.,  1.]),
       0.0)
```

```
[21]: sla.solve(a,b)
```

```
[21]: array([ 1., -1.,  1.])
```

O resultado obtido está de acordo com o cálculo analítico

### Example 6

$$\begin{bmatrix} \varepsilon & 2 \\ 1 & \varepsilon \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} 4 \\ 3 \end{bmatrix} \quad (1)$$

**Exercise 5** Verifique o exemplo 6 para valores pequenos de  $\varepsilon$ , usando as funções com e sem pivotamento parcial.

```
[22]: e = 1e-1

a = np.array([e, 2], [1, e])
b = np.array([4, 3])
```

```
[23]: elimin_gaussiana(a, b)
```

```
[23]: (matrix([[ 0.1,  2. ],
               [ 0. , -19.9]]),
       matrix([[ 4.],
               [-37.]]),
       array([[2.81407035],
              [1.85929648]]),
       8.881784197001252e-16)
```

```
[24]: elimin_gaussiana_pivoteamento_parcial(a,b)
```

```
[24]: (array([[1. , 0.1 ],
            [0. , 1.99]]),
      array([3. , 3.7]),
      array([2.81407035, 1.85929648]),
      0.0)
```

```
[25]: sla.solve(a,b)
```

```
[25]: array([2.81407035, 1.85929648])
```

```
[26]: e = 1e-100
```

```
[27]: elimin_gaussiana(a, b)
```

```
[27]: (matrix([[ 0.1,  2. ],
              [ 0. , -19.9]]),
      matrix([[ 4.],
              [-37.]]),
      array([[2.81407035,
              1.85929648]]),
      8.881784197001252e-16)
```

```
[28]: elimin_gaussiana_pivoteamento_parcial(a,b)
```

```
[28]: (array([[1. , 0.1 ],
            [0. , 1.99]]),
      array([3. , 3.7]),
      array([2.81407035, 1.85929648]),
      0.0)
```

```
[29]: sla.solve(a,b)
```

```
[29]: array([2.81407035, 1.85929648])
```

É possível observar que para o valor de  $e = 0,1$  houve um dos métodos que apresetaram erro de cálculo, demonstrando assim o efeito do cancelamento catastrófico